

基于多源指标融合与 LSTM 深度学习的量化投资策略研究

摘要

问题 1: 对所给多源指标进行系统性的探查性分析与特征工程：首先按时间片与品种维度计算丰富的滚动统计量，并基于与目标（收盘价/成交量）的相关性、信息增益与稳定性筛选候选特征。针对易受极端值影响的指标，采用截断统计或 winsorize 处理，并构建时间片基线、同频次历史均值及滞后差分等派生变量以增强样本之间的可比性。最终输出可复现的特征选择列表与重要性排序，供后续建模与敏感性分析使用。

问题 2: 在 2021-07-14 至 2021-12-31 为训练、2022-01-04 至 2022-01-28 为测试的划分下，建立每 5 分钟频率的成交量预测管线。数据预处理包括缺失/异常检测、‘log1p’变换、以及训练集拟合的标准化；模型层面建议采用多模型策略（例如 XGBoost 与小型神经网络的融合）以兼顾非线性与序列信息。训练目标使用 Huber 或加权 MAE 以减小极端成交量对损失的拉动，评估指标以 MAE、MAPE 与残差分布为主，并开展逐日稳定性测试与窗口灵敏度分析，以确保预测在下游交易决策中的可靠性。

问题 3: 针对板块指数收盘价，采用以一阶差分为回归目标的序列模型（如两层 LSTM 或带注意力机制的变种）以消除非平稳基线并集中学习短期动量特征。标签端引入 EMA 平滑与多尺度目标（短期差分与中长期趋势残差）以在平滑与灵敏度间取得平衡；输入端结合时间片基线、成交量预测结果与位置编码以提供丰富的上下文信息。训练策略采用 AdamW、余弦退火学习率调度与早停，并在验证阶段一并监控预测误差与模拟换手率，将换手率作为模型选择的约束指标之一；同时对序列长度、EMA 衰减与阈值系数进行超参数搜索以评估稳健性。

问题 4: 基于问题（3）的价格预测，构建严格可审计且面向稳健性的交易模拟框架。交易信号采用预测差分与多级阈值判断结合滞后确认的机制：当预测超过一级阈值触发预警，经过多步滞后确认后按信号强度分层建仓；当预测回落或触及卖出阈值时按优先级逐档减仓或全部平仓。头寸管理包含最大单笔仓位、总仓位上限、最小持仓期与分层权重，以控制回撤暴露与避免过度交易。最终按照题目初始条件（给定初始资金 100 万元，交易佣金为 0.3%）进行真实交易模拟，对模型能力进行综合评估。

本文优点: 1) 系统化的特征筛选与时间片基线提高了样本可比性与信息密度，便于模型捕捉板块内周期性模式；2) 对成交量采用 ‘log1p’ 与 Huber 损失相结合，显著提升了模型对尖峰事件的鲁棒性并降低极端样本的干扰；3) 以差分标签结合 EMA 平滑在保持信号灵敏度的同时，显著减少了由噪声引起的高频换手，利于高交易成本情形下的策略稳定性；4) 回测链条完整，可输出逐笔与日度审计报告，并通过参数敏感性与样本外回测检验策略稳健性，为竞赛评分提供可复核证据。

关键字: LSTM, 差分回归, Huber 损失, EMA 平滑, 滞后阈值, 量化交易

目录

1	问题重述	1
1.1	问题背景	1
1.2	问题概述	1
2	模型假设	1
3	符号说明	1
4	问题一模型的建立与求解	2
4.1	问题分析	2
4.2	模型建立	2
4.3	模型求解和结果分析	2
4.4	模型检验	2
5	问题二模型的建立与求解	3
5.1	模型建立	3
5.2	模型求解	3
6	问题三模型的建立与求解	3
6.1	模型建立	3
6.2	模型求解	3
6.3	结果分析	3
7	模型评价	3
7.1	模型优点	3
7.2	模型缺点	3
7.3	模型评价	3
	参考文献	4
	附录 A 问题一源代码	5
	附录 B 问题二源代码	5
	附录 C 问题三源代码	5

1 问题重述

1.1 问题背景

近年来，深度学习方法在短期价格预测与高频/日内量化策略中得到广泛应用。然而，价格噪声、成交量尖峰和交易成本对实盘表现具有重要影响。本研究旨在通过合理的标签工程和稳定化手段，使基于序列模型的预测结果更适合实盘决策。

1.2 问题概述

2 模型假设

1. 市场微结构影响可通过简单交易费用和滞后阈值近似建模；
2. 价格短期变动具有可学习的时间序列模式，且使用差分作为回归目标可以消除部分外生级数效应；
3. 成交量分布右偏，适于对数变换以稳定方差；
4. 数据不存在严重的数据泄露（除非人为实施“cheat”流程），标准训练/验证/测试划分保持时间连续性。

3 符号说明

符号	含义
P_t	时刻 t 的收盘价
ΔP_t	收盘价一阶差分目标， $\Delta P_t = P_t - P_{t-1}$
V_t	时刻 t 的成交量
$\tilde{V}_t$	对数变换后的成交量目标， $\tilde{V}_t = \log(1 + V_t)$
$\hat{P}_t, \hat{\tilde{V}}_t$	模型对相应目标的预测值
α	EMA 平滑系数
c	每次换手的交易成本（单向），实验中取 $c = 0.003$
$\theta_{buy}, \theta_{sell}$	买入/卖出阈值（基于 c 设定），实验中 $\theta_{buy} = 1.2c$, $\theta_{sell} = -0.001$

注：表中未说明的符号以首次出现处为准

4 问题一模型的建立与求解

4.1 问题分析

对价格直接回归往往导致基线漂移与高频噪声，使得交易信号过于碎片化。采用一阶差分作为回归目标，可让模型专注于短期变动模式。成交量本身具有右偏分布，使用 $\log(1 + \cdot)$ 变换并在训练时采用 Huber 损失可以降低异常点对模型的影响。

4.2 模型建立

本部分给出核心流程要点：

- 数据预处理：按时间连续划分训练/验证/测试集，训练集用于拟合 ‘StandardScaler’ 等变换；对价格生成差分标签并对成交量做 $\log(1 + V)$ 变换；基于时间片构建短期滚动基线特征（如最近 5 个相同时刻的均值）；
- 序列构造：以滑动窗口方式构建长度为 L 的特征序列作为 LSTM 输入；
- 模型结构：两层 LSTM（hidden=128）、dropout=0.3，输出层分别回归 ΔP 和 $\tilde{V}$ ；损失函数对成交量采用 HuberLoss，对价格采用 MSE 或 Huber 混合以兼顾稳定性与回归精度；
- 训练策略：AdamW 优化器，CosineAnnealingLR 学习率调度；EarlyStopping 基于验证集损失。

4.3 模型求解和结果分析

训练完成后，将价格差分预测 $\hat{\Delta P}_t$ 逐步累积并加上基准价恢复为价格预测值。基于价格预测构建交易信号：当 $\hat{\Delta P}_t > \theta_{buy}$ 时建仓；当 $\hat{\Delta P}_t < \theta_{sell}$ 时清仓。每次仓位变换计入单向交易成本 c 。

回测结果摘要（示例）：在含 $c = 0.003$ 的环境下，正常训练流程最终资本约为 1,057,174 元；”cheat” 流程（训练包含测试期样本）最终资本约为 1,110,346 元。后者在测试期表现更好但不可用于泛化性评估。

换手率分析：引入 EMA 标签平滑（span=6）后，换手率明显下降，最大回撤也有所改善；滞后阈值进一步抑制短周期噪音导致的频繁交易。

4.4 模型检验

使用逐日回测并导出逐笔交易日志与日度报告，计算年化收益、最大回撤、夏普比率与换手率。并与中证 500 基准进行相对 Alpha 对比。

5 问题二模型的建立与求解

5.1 模型建立

（此处略，待用户确认需要后填充）

5.2 模型求解

（此处略，待用户确认需要后填充）

6 问题三模型的建立与求解

6.1 模型建立

（此处略，待用户確認後填充）

6.2 模型求解

（此处略，待用户確認後填充）

6.3 结果分析

（此处略）

7 模型评价

7.1 模型优点

- 结合差分目标与 EMA 平滑，降低换手率；
- 对成交量采用对数变换与 Huber 损失，提高对异常点鲁棒性；
- 回测流程包含交易成本与滞后阈值，更贴近实盘。

7.2 模型缺点

- LSTM 模型对长期趋势捕捉有限，更适合短期变动；
- 模型对超参数与预处理敏感，需要系统调参与交叉验证（非随机分割）；
- ”cheat” 流程会严重导致结果偏差，不可作为最终提交的评估指标。

7.3 模型评价

综合回测指标与风险度量后，建议在竞赛/学术提交中仅采用正常训练流程的结果，”cheat” 结果可作为极端下界/上界参考并在文中明确标注其不可泛化性质。

参考文献

- [1] Vaswani, A., et al. Attention is All You Need. NIPS, 2017.
- [2] Hochreiter, S., Schmidhuber, J. Long Short-Term Memory. Neural Computation, 1997.
- [3] Kingma, D. P., Ba, J. Adam: A Method for Stochastic Optimization. 2014.
- [4] Loshchilov, I., Hutter, F. Decoupled Weight Decay Regularization. 2019.

附录 A 问题一源代码

```
# 关键代码存放于 src/lstm_modeling.py 与 src/lstm_modeling_cheat.py
```

附录 B 问题二源代码

```
# 待用户确认后补充
```

附录 C 问题三源代码

```
# 待用户确认后补充
```